

Построение VoR-дерева с использованием технологии MapReduce

Амосов Федор, СПбГУ

Руководитель: Волохов Антон, Яндекс

Постановка задачи

Дано

- 10^9 точек из \mathbb{R}^5
- Метрика
- Кластер из 10^3 машин

Задача

- Распараллеленно построить структуру для эффективных 1-NN и k -NN запросов в данной метрике

VoR-дерево

Определение

- VoR-дерево = R-дерево + диаграмма Вороного

В нашей задаче

- Евклидова метрика — ?
- 1-NN запрос за $O(\log n)$
- k -NN запрос за $O(k + \log n)$

R-дерево

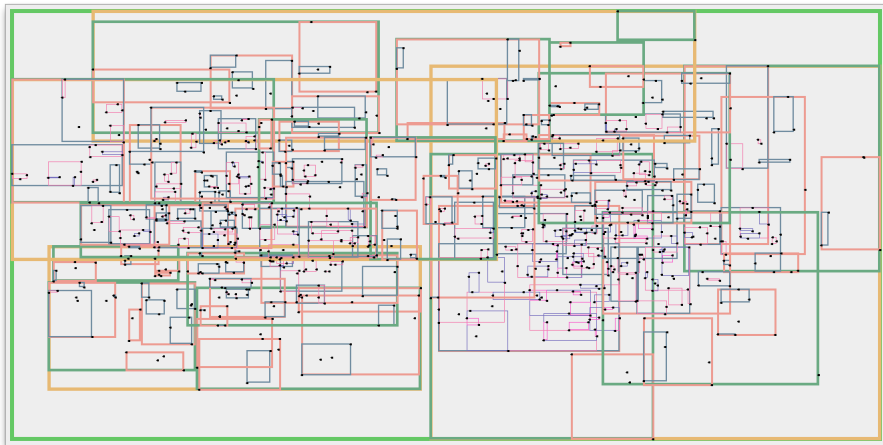


Диаграмма Вороного







Диаграмма Вороного



Граф Делоне




Основное свойство графа Делоне



Плохие и хорошие треугольники

Картинка с плохими и хорошими треугольниками

VoR-дерево



Sharifzadeh , M., Shahabi C., «VoR-Tree: R-trees with Voronoi Diagrams for Efficient Processing of Spatial
Nearest Neighbor Queries» Proceedings of the VLDB Endowment, 2010

Построение VoR-дерева

- offline
- Требование распараллеленности \implies «разделяй и властвуй»
- Построить R-дерево за $O(n)$ — очевидно
- Построить граф Делоне за $O(n \log n)$, следуя парадигме «разделяй и властвуй» — ?

Построение графа Делоне 1

Картинка с точками

Построение графа Делоне 2

Картинка с выделенными пайвотами

Построение графа Делоне 3

Картинка с разделением на части

Построение графа Делоне 4

Картинка с построенными графами Делоне

Построение графа Делоне 5

Картинка с выделенными плохими треугольниками

Построение графа Делоне 6

Картинка с удаленными плохими треугольниками

Построение графа Делоне 7

Картинка с хорошо выделенными граничными точками
и более тускло все остальное

Построение графа Делоне 8

Картинка как предыдущая, только со склеивающим
графом Делоне

Построение графа Делоне 9

Из предыдущей картинки выкидываются «ненужные»
ребра

Построение графа Делоне 10

Все в цвете

Построение графа Делоне 11

Итоговый граф Делоне

Анализ алгоритма

- 2 утверждения \implies корректность
- Ускорение внешнего «склеивающего» алгоритма
 - $O(n^2) \longrightarrow O(n \log n)$
 - $O(n^k) \longrightarrow O(n^{\frac{k}{2}}), k > 2$


Улучшение алгоритма

- ❶ Плохие треугольники находятся вблизи границы \implies не надо проверять все треугольники
- ❷ Будем строить нашим алгоритмом сразу VoR-деревья \implies определение «хорошести» треугольника с помощью построенных VoR-деревьев
- ❸ Склеивание можно проводить с помощью рекурсивного вызова нашего алгоритма. В чем подвох?
- ❹ Внешний алгоритм только для маленьких задач

Итого, сложность всегда $O(n \log n)$

На практике

Ускорение наивного алгоритма



Картинка с разбиением на части

Технология MapReduce

Технология

- Map — обработка данных — построение VoR-деревьев из частей
- Reduce — свертка данных — склеивание полученных VoR-деревьев

Реализация

- Apache Hadoop
- Сериализация VoR-дерева — Google Protocol Buffers

Результаты

Разработан алгоритм построения многомерного VoR-дерева

- Асимптотически эффективный
- Хорошо параллелится
- Реализован на Java
- Реализован с использованием MapReduce
- Реализован с использованием MapReduce рекурсивно

До 10^9 точек еще далеко, но прототип работает

Спасибо за внимание!