Построение VoR-дерева с использованием технологии MapReduce

Амосов Федор, СПбГУ

Руководитель: Волохов Антон, Яндекс

Постановка задачи

Дано

- ullet 10 9 точек из \mathbb{R}^5
- Метрика
- Кластер из 10³ машин

Задача

• Распараллеленно построить структуру для эффективных 1-NN и k-NN запросов в данной метрике

VoR-дерево

Определение

• VoR-дерево = R-дерево + диаграмма Вороного

В нашей задаче

- Евклидова метрика ?
- 1–NN запрос за $O(\log n)$
- k-NN запрос за $O(k + \log n)$

R-дерево

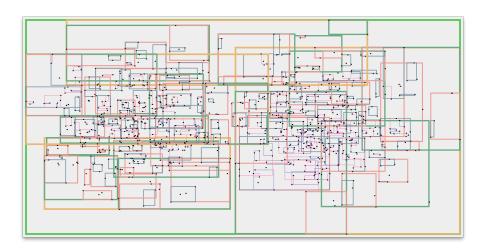


Диаграмма Вороного

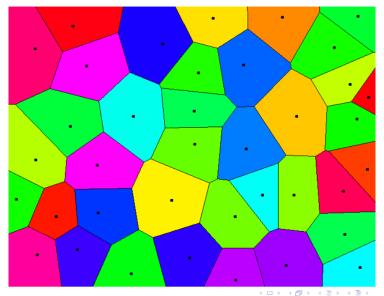
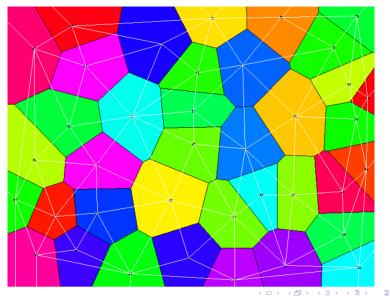
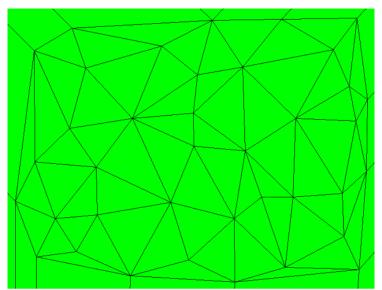


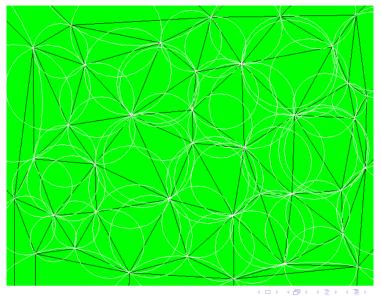
Диаграмма Вороного



Граф Делоне



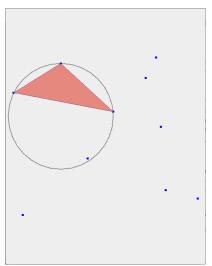
Основное свойство графа Делоне

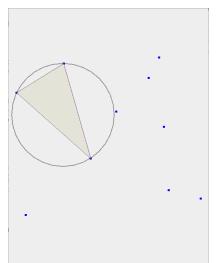


Плохие и хорошие треугольники

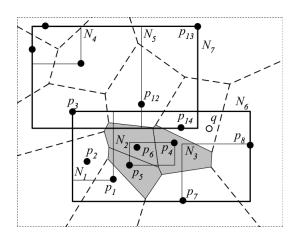
Плохой треугольник

Хороший треугольник





VoR-дерево

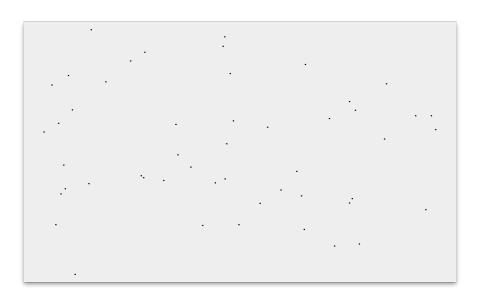


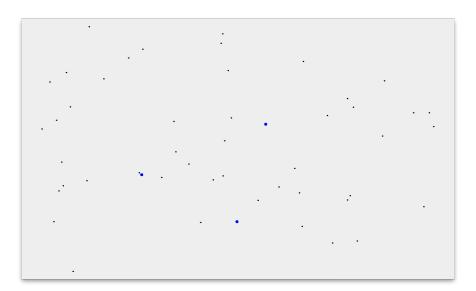
Sharifzadeh , M., Shahabi C., «VoR-Tree: R-trees with Voronoi Diagrams for Efficient Processing of Spatial

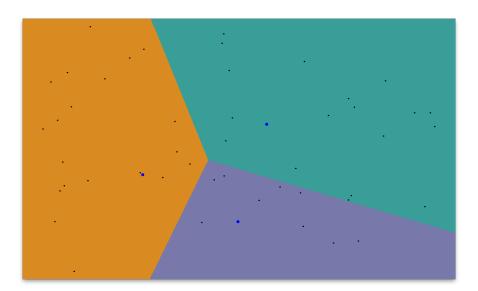
Nearest Neighbor Queries» Proceedings of the VLDB Endowment, 2010

Построение VoR-дерева

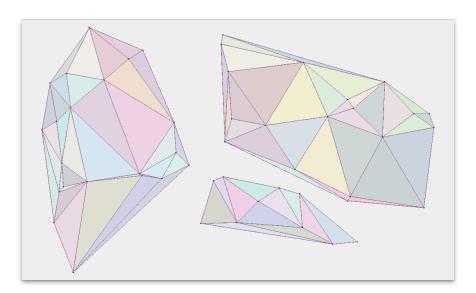
- offline
- Требование распараллеленности => «разделяй и властвуй»
- ullet Построить R-дерево за O(n) очевидно
- Построить граф Делоне за $O(n \log n)$, следуя парадигме «разделяй и властвуй» ?

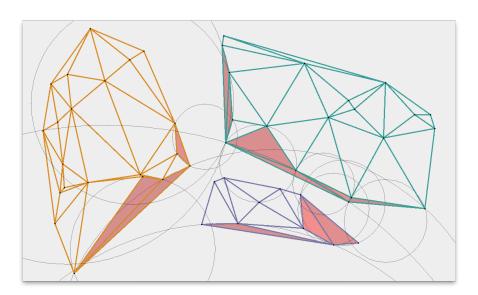


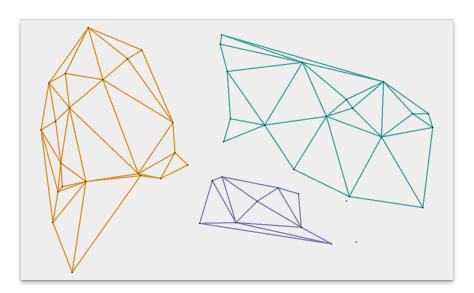


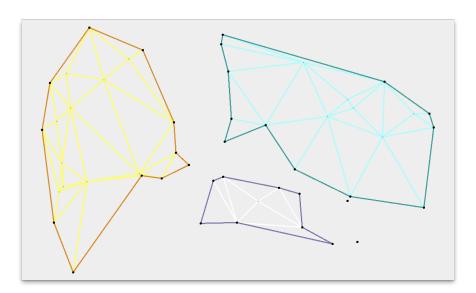


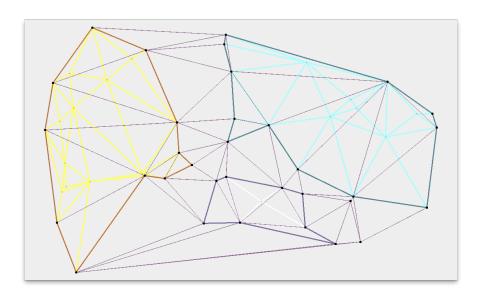


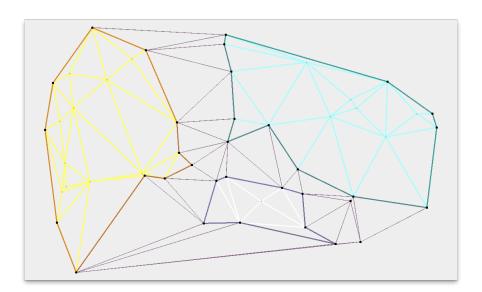


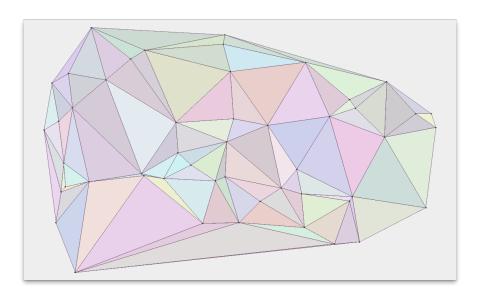












Наш алгоритм

- Разбить множество точек на несколько частей*
- Построить на каждой части граф Делоне
- Удалить в каждом построенном графе «плохие» треугольники
- Добавить все оставшееся в итоговый граф
- Построить на границах оставшегося «склеивающий» граф Делоне
- Добавить в итоговый граф ребра «склеивающего» графа
 - соединяющие разные части
 - удаленные на 3 этапе



Анализ алгоритма

- 2 утверждения \Longrightarrow корректность
- Ускорение внешнего «склеивающего» алгоритма
 - $O(n^2) \longrightarrow O(n \log n)$
 - $O(n^k) \longrightarrow O(n^{\frac{k}{2}}), k > 2$

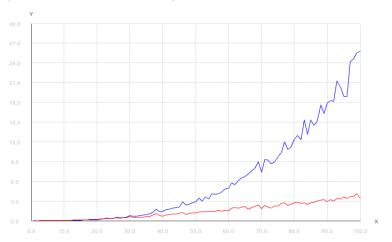
Улучшение алгоритма

- Плохие треугольники находятся вблизи границы
 ⇒ не надо проверять все треугольники
- Образов Вудем строить нашим алгоритмом сразу VoR-деревья ⇒ определение «хорошести» треугольника с помощью построенных VoR-деревьев
- Оклеивание можно проводить с помощью рекурсивного вызова нашего алгоритма. В чем подвох?
- Внешний алгоритм только для маленьких задач

Итого, сложность всегда $O(n \log n)$

На практике

Ускорение наивного алгоритма

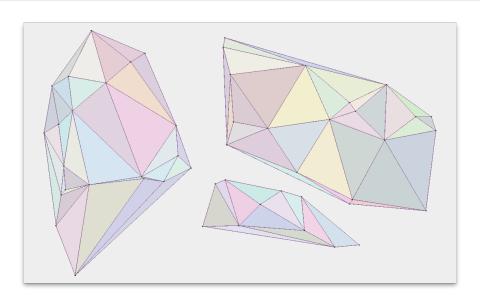


Время работы от размера задачи

Распараллеливание 1



Распараллеливание 2



Технология MapReduce

Технология

- Мар обработка данных построение VoR-деревьев из частей
- Reduce свертка данных склеивание полученных VoR-деревьев

Реализация

- Apache Hadoop
- Сериализация VoR-дерева Google Protocol Buffers

Результаты

Разработан алгоритм построения многомерного VoR-дерева

- Асимптотически эффективный
- Хорошо параллелится
- Реализован на Java
- Реализован с использованием MapReduce
- Реализован с использованием MapReduce рекурсивно

До 10^9 точек еще далеко, но прототип работает

Q&A

Спасибо за внимание! github.com/amosov-f/VorTree